0.获得的数据是怎么组成的?

表达矩阵

example

```
           sample1  sample2  sample3
GeneA        5.2      4.9      6.1
GeneB        0.3      0.1      0.2
GeneC       10.8     11.2      9.9
```

- 行：被测的对象（基因 / 探针）
- 列：一次完整的观测（一个人 / 一块组织）
- 数值：仪器给出的信号强度（RNA 多不多）

样本信息（条件/状态）

example

```
        disease   age   sex
sample1   AD      72    F
sample2   AD      68    M
sample3 Control   70    F
```

基因注释（把基因翻译成人话）

example

```
        GeneSymbol   EntrezID    Description
GeneA      TP53        7157    tumor suppressor
GeneB      IL6         3569    cytokine
```

1.总体的流程

0.数据来源

数据源	在 R 里的“容器”
GEO	ExpressionSet
TCGA	SummarizedExperiment
自己实验	matrix / data.frame

1.统一处理

数据源	表达矩阵	样本信息
TCGA	`assay(tcga_data)`	`colData(tcga_data)`
GEO	`exprs(gse)`	`pData(gse)`

2.质量控制（QC）

基因层面

```
# 例：去掉几乎不表达的基因
expr <- expr[rowSums(expr > 1) >= 10, ]
```

样本层面

```
boxplot(log2(expr + 1))   # 例：样本分布是否离谱
```

3.标准化

GEO

```
expr <- normalizeBetweenArrays(expr)
expr <- log2(expr + 1)
```

TCGA

```
dds <- DESeqDataSetFromMatrix( # 把数据装进一个统计模型容器
  countData = expr,
  colData = pheno,
  design = ~ group_list
)
dds <- DESeq(dds) # 标准化
expr <- assay(vst(dds)) # 把 count 数据变成“看起来像芯片数据”的形式
```

4.分组

```
group_list <- ifelse(
  pheno$sample_type == "Solid Tissue Normal",
  "normal",
  "tumor"
)
group_list <- factor(group_list, levels = c("normal", "tumor"))
```

5.差异分析

```
design <- model.matrix(~ group_list)

deg <- lmFit(expr, design) |>
  eBayes() |>
  topTable(coef = 2, number = Inf)
```

deg

列名	含义
logFC	差异方向和大小
P.Value	显著性
adj.P.Val	多重校正后 P 值

6.标记上下调

```
deg$change <- "stable"
deg$change[deg$logFC > 1 & deg$P.Value < 0.05] <- "up"
deg$change[deg$logFC < -1 & deg$P.Value < 0.05] <- "down"
```

7.最后成果

- deg（差异基因表）
- 上调 / 下调基因列表
- 送去画图

2.QC 小技巧（用dplyr思路同理）

行 = 基因

列 = 样本

目的	写
筛基因	`[行, ]` / `rowSums` / `rowMeans`
筛样本	`[, 列]` / `colData()`
表达数据	`assay()` / `counts()`
样本标签	`colData()`
同步操作	直接对对象 `[ , ]`

3.deg详解

前置条件

```
expr        # 表达矩阵：行=基因，列=样本
pheno       # 样本信息
group_list  # 样本分组（normal / tumor）
```

1.构建设计矩阵（告诉R比较对象）

```
design <- model.matrix(~ group_list)
```

输出：

样本	normal 组?	tumor 组?
sample1	是	否
sample3	否	是

对每个基因做数学比较

拟合线性模型

```
# 对 每一个基因用 design 里的分组信息拟合一个模型
# 比较两组差异
fit <- lmFit(expr, design)
```

经典贝叶斯

```
# 让所有基因“互相参考”来稳定统计结果
fit2 <- eBayes(fit)
```

生成deg

```
# coef = 2 = 比较 tumor vs normal
deg <- topTable(fit2,coef = 2, number = Inf)
```

4.关于画图

0.概览

```
所有图 = 从一个表中
1.选几列
2.指定“谁当 x，谁当 y，谁当颜色/形状”
```

核心架构

```
# 可以理解为指定哪列画横轴，哪列画纵轴，哪列用颜色区分
ggplot(data, aes(x = ?, y = ?, color = ?)) +
geom_xxx() # 画什么图
```

1.火山图

回答：哪些基因变得多又显著?

数据来源：deg表

设计逻辑

轴	含义
x	logFC（变化大小）
y	-log10(P)（显著性）
color	上调 / 下调

示例代码

```
library(ggplot2)

ggplot(deg, aes(x = logFC, y = -log10(P.Value), color = change)) +
  geom_point(alpha = 0.6) +
  theme_minimal()
```